

Речь к защите магистерской диссертации

Детектирование нефтяных разливов в арктических портах по данным Sentinel-1 · ≈ 6–7 минут

Слайд 1 — Титульный

Здравствуйте, уважаемые члены комиссии! Тема моей работы — разработка системы автоматического детектирования нефтяных разливов в акваториях арктических портов по данным спутниковой радиолокации. Научный руководитель — кандидат технических наук, доцент Митько Арсений Валерьевич. Позвольте начать с цели и задач исследования.

Слайд 2 — Цель и задачи

Цель работы — создать систему, которая по радарным снимкам Sentinel-1 автоматически находит нефтяные разливы и при этом не путает их с похожими тёмными пятнами. Для этого я поставил пять задач: изучить физику радиолокации нефти и систематизировать ложные цели; реализовать конвейер предобработки в SNAP и QGIS; собрать трёхклассовый датасет; адаптировать и обучить нейросеть DeepLabV3+; и проверить перенос модели на новые порты. Но прежде чем переходить к решению, важно понять масштаб самой проблемы.

Слайд 3 — Актуальность

Почему эта тема актуальна. Ежегодно в Мировой океан попадает более 700 тысяч тонн нефти, а в холодной арктической воде она разлагается в 5–10 раз медленнее. При этом оптические спутники здесь почти бесполезны: больше 80 процентов времени мешают облака и полярная ночь. Два показательных случая: разлив в Кольском заливе в августе 2024 года, который мы подтвердили нашей системой, и крупнейшая авария в Норильске в 2020-м — 21 тысяча тонн дизтоплива, штраф 146 миллиардов рублей. Возникает вопрос: как надёжно обнаруживать такие разливы в Арктике? Ответ — спутниковая радиолокация.

Слайд 4 — Данные и метод (SAR + датасет)

Почему именно радар? Радар Sentinel-1 работает круглосуточно и сквозь облака, данные бесплатны. Физика простая: нефть гасит мелкую рябь на воде — это эффект Марангони — и на снимке появляется тёмное пятно. Но главная сложность именно здесь: такие же тёмные пятна дают молодой лёд, зоны штиля и биоплёнки. Это ложные цели, и до 70 процентов тёмных пятен в Арктике — это лёд, а не нефть. Поэтому я разметил датасет на три класса: вода, нефть и лёд с сушей — впервые выделив лёд в отдельный класс. Источник данных — Copernicus, ESA. Но сырой снимок нельзя подавать в сеть напрямую — сначала его нужно подготовить.

Слайд 5 — Предобработка: ESA SNAP и QGIS

Подготовка нужна потому, что радарные данные содержат шум и геометрические искажения, и идёт она в два этапа. На первом этапе в ESA SNAP восемь шагов:

уточнение орбиты, снятие теплового шума антенны, калибровка в коэффициент обратного рассеяния, подавление спекл-шума фильтром Ли семь на семь, наложение маски суши и воды по SRTM с расширением берега на десять пикселей, коррекция геометрии по методу Range-Doppler, адаптивная детекция тёмных зон с порогом $T = \mu - 1.3\sigma$ и кластеризация с минимальным размером 300 пикселей — на выходе GeoTIFF. На втором этапе в QGIS я загружаю полученные GeoTIFF, уточняю береговую линию, размечаю эталонные участки нефти, льда и воды, собираю трёхклассовые маски и нарезаю на тайлы 256 на 256 с перекрытием. Итого — более четырёх тысяч геопривязанных тайлов с масками для обучения. Прежде чем рассказать о самой нейросети, покажу, как система отрабатывает на реальных разливах.

Слайд 6 — Кейс А: реальные разливы (Кольский + Норильск)

Рассмотрим два реальных случая. Первый — Кольский залив, лето 2024. На слайде показан реальный временной ряд из одиннадцати снимков Sentinel-1, загруженных из архива ASF DAAC и обработанных в ESA SNAP. Период — с первого июля по тридцатое августа. На снимке от восемнадцатого августа — через семь суток после утечки при бункеровке — модель зафиксировала тёмное пятно: 13.7 процента акватории, максимум за весь ряд. Чтобы убедиться, что это нефть, а не двойник, применялась двойная проверка. ERA5 — реанализ погоды Европейского центра ECMWF — показал ветер 4.8 метра в секунду, в диапазоне, где плёнка ещё видна на радаре. AIS — система автоматической идентификации судов — подтвердила судно в пяти километрах от пятна. Результат: F1 равен 0.89, точность 95.8 процента. Второй случай — Норильск, май 2020, крупнейшая катастрофа: 21 тысяча тонн дизтоплива. Здесь важно быть честным: разлив был на суше и в реках, поэтому мониторинг вёлся оптикой Sentinel-2 — радар здесь не применим. Этот случай показывает, насколько критичен надёжный мониторинг акваторий. А самая большая сложность такого мониторинга — те самые ложные цели, и о них следующий слайд.

Слайд 7 — Кейс В: ложные цели в действии (Варандей / Печенга / Сабетта)

Теперь о главной сложности — ложных целях в действии. Мы протестировали модель на трёх новых портах: Варандей, Печенга и Сабетта. На снимках везде видны тёмные аномалии. Но не все они — нефть! Молодой лёд — жировой, нилас, шуга — гасит рябь точно так же, как нефть, и выглядит на радаре почти неотличимо. Это и есть ложные цели. Посмотрим на цифры: на Кольском заливе доля ложных тревог — 1.4 процента, на Сабетте она вырастает до 6.2. Вот почему наш F1 снижается с 0.89 на Кольском до 0.76 на Сабетте. Именно для решения этой проблемы мы выделили лёд в отдельный третий класс — это ключевой элемент нашей научной новизны. Теперь посмотрим, как построена сама нейросеть, которая различает эти классы.

Слайд 8 — Модель DeepLabV3+

Для автоматического распознавания я адаптировал нейросеть DeepLabV3+. Энкодер ResNet-50 перестроен под одноканальные радарные данные, блок ASPP улавливает объекты разного масштаба — от небольшого пятна до крупного разлива, а блоки

внимания scSE подавляют шум и усиливают нефтяные пятна. Поскольку нефти на снимках очень мало — всего 2.4 процента — обучение шло с сильной балансировкой классов и комбинированной функцией потерь. Перейдём к тому, каких результатов удалось достичь.

Слайд 9 — Результаты и метрики

Результаты. На Кольском заливе модель достигла точности 95.8 процента. Поясню метрики, чтобы не осталось вопросов. mIoU 0.82 означает, что 82 процента площади по всем трём классам классифицированы верно. F1 по нефти 0.89 — это баланс полноты и точности: из 100 нефтяных пятен 89 найдено, и 89 процентов найденного — действительно нефть. Сама детекция тёмных зон опирается на адаптивный порог: T равен среднему минус 1.3 стандартных отклонения яркости воды — всё, что темнее, считается кандидатом в нефть и затем проверяется сетью. Кривые обучения слева показывают устойчивую сходимость без переобучения, а график справа внизу — перенос модели: F1 снижается с 0.89 на Кольском до 0.76 на Сабетте, и причину мы уже объяснили — там больше льда. Теперь обобщу, в чём именно состоит научная новизна работы.

Слайд 10 — Научная новизна и сравнение с аналогами

Научная новизна работы — в трёх вещах. Первое: первый трёхклассовый датасет для российской Арктики, где лёд выделен в отдельный класс — это прямое решение проблемы ложных целей. Второе: адаптация DeepLabV3+ под одноканальный радарный вход. Третье: впервые количественно измерена деградация качества при переносе модели на новые порты. На графике справа видно, что наш метод превосходит все аналоги из литературы: F1 равен 0.89 против 0.86 у ближайшего конкурента — адаптивного порога — и 0.80 у U-Net. И в завершение — общие выводы по работе.

Слайд 11 — Выводы и практическая значимость

Итог. Создан полный рабочий конвейер: от обработки снимка в SNAP и QGIS, через сегментацию нейросетью, до верификации результата по метеоданным и судовому трафику. Собран первый трёхклассовый датасет для российской Арктики из 1125 сцен. Достигнут F1 0.89 — выше всех аналогов из литературы. Метод проверен на четырёх портах, и мы объяснили, почему F1 снижается: виноват молодой лёд как ложная цель — именно эту проблему решает наш трёхклассовый подход. Система готова к практическому мониторингу. Спасибо за внимание, готов ответить на вопросы.